

프레임 수준 동영상 해석 극대화를 통한 효율적인 Video Temporal Grounding 연구

강지현¹, 김수용², 노하림³, 양희재^{4,⊙}

연세대학교 전기전자공학부¹, 서울대학교 협동과정 인공지능전공², 덕성여자대학교

컴퓨터공학전공³, 성균관대학교 인공지능학과^{4,⊙}

e-mail : danieljiheon@yonsei.ac.kr, ksynt1111@snu.ac.kr, doris5093@duksung.ac.kr,
neulbo1126@skku.edu

Frame-Level Understanding for Lightweight and Explainable Video Temporal Grounding

Jiheon Kang¹, Sooyong Kim², Harim Noh³, Heejae Yang^{4,⊙}

Electrical and Electronic Engineering, Yonsei University¹, Interdisciplinary Program in
Artificial Intelligence, Seoul National University², Computer Engineering, Duksung Women's
University³, Department of Artificial Intelligence, Sungkyunkwan University^{4,⊙}

Abstract

This study presents a lightweight framework for addressing the Video Temporal Grounding (VTG) task using only frame-query similarity. The proposed method operates without any additional training, utilizing a single pre-trained Vision-Language Model (VLM) and requiring less than 1GB of GPU memory. It achieves up to approximately 61% performance improvement over existing training-free methods under comparable settings. In addition, the adoption of an intuitive boundary-based segment generation enhances the explainability of the model. The framework also demonstrates strong generalization capability by being extended to the Video Moment Retrieval (VMR) task without any structural modification.

I. 서론

최근 온라인 플랫폼의 확산으로 비디오 콘텐츠의 양이 급증함에 따라, 이를 효과적으로 분석하고 이해하기 위한 연구가 활발히 진행되고 있다. 특히, 자연어 질의에 기반하여 영상 내 특정 시간 구간을 자동으로 탐색하는 Video Temporal Grounding (VTG)은 중요한 비디오 이해 과제로 주목받고 있다. 기존 VTG 연구는 대부분 복잡한 구조의 비디오 인코더 또는 Fine-tuning에 의존하여, 연산 자원이 많이 요구되는 한계가 있었다.^{[1][2][3][4]} 이를 극복하기 위해 사전학습된 Vision-Language Model (VLM)을 활용한 Training-free 방식이 제안되었으나, 여전히 프롬프트 설계나 LLM 사용 등으로 실질적 경량화에는 한계가 존재했다.^[5]

본 연구는 단일 VLM만을 활용하여 프레임과 쿼리 간 유사도의 시간적 변화를 기반으로 구간을 탐지하는

⊙ Corresponding author.

간결한 VTG 프레임워크를 제안한다. 별도의 학습 없이 동영상 내 의미 있는 구간을 효과적으로 추출하며, 모델의 판단 과정을 직관적으로 해석할 수 있는 장점을 가진다. 또한 VTG에 국한되지 않고 비디오 내 구간을 검색하는 Video Moment Retrieval(VMR)로 확장을 통해 높은 활용 가능성을 보였으며, 경량성과 성능 측면에서도 모두 경쟁력을 갖춘 접근법임을 실험을 통해 입증하였다.

II. 본론

본 연구는 동영상을 일련의 정적인 프레임 시퀀스로 해석하되, 프레임 간 의미 변화의 흐름을 분석함으로써 시간적 특성을 간접적으로 반영한다. 각 프레임과 쿼리 간의 의미적 일치도를 VLM을 통해 정량화한 뒤, 이를 시간순으로 연결하여 유사도 곡선을 형성한다. 이후 해당 곡선에 대해 후처리를 수행하고 변화 양상을 분석함으로써, 구간 추출에 필요한 시간적 경계를 효과적으로 식별한다. 본론에서는 이러한 모델 처리 과정을 단계별로 설명한다.

2.1 Frame-Query Similarity

동영상을 프레임 단위로 자르고, 프레임과 텍스트 쿼리를 VLM (CLIP VIT-B/32^[6])을 이용하여 유사도를 구한다.

$$s_t = \text{sim}(f_t, q) = \frac{f_t \cdot q}{\|f_t\| \cdot \|q\|} \quad (f = \text{frame}, q = \text{query}) \quad (1)$$

프레임 이미지와 쿼리 사이의 코사인 유사도를 사용하여 프레임-쿼리 유사도를 계산하고, 이를 시간순으로 나열한 곡선을 구간 추론에 사용한다.

2.2 Edge Focused Curve Post-processing

비디오에서 장면 전환이나 조명 변화 등의 다양한 요인으로 인해 프레임-쿼리 유사도 곡선이 쉽게 왜곡되며, 이는 구간 탐지의 정확도를 크게 저해한다. 이러한 왜곡을 보정하고 신뢰도 높은 결과를 얻기 위해서는 적절한 후처리 과정은 필수적이다.

특히 전체 구간을 대략적으로 추정하기보다, 시작과 종료 시점을 명확히 구분하는 것이 중요하다. 시간적 경계를 명확히 설정하지 못하면 생성된 구간의 의미가 모호해지고, 쿼리와 대응 관계를 해석하기 어려워지기 때문이다. 실제로 유사도 곡선은 이벤트의 시작에서 급증하고 종료에서 급락하는 경향을 보이므로, 유사도 자체보다는 변화율에 주목하는 방식이 더 효과적이다.

따라서 본 연구는 이러한 유사도 변화의 흐름을 정교하게 분석함으로써 이벤트 경계를 정밀하게 포착하고자 하였으며, 이를 위한 후처리 과정은 다음의 가-나-다 단계로 구성하였다.

가) Gaussian Smoothing

프레임 단위의 유사도에서 잦은 노이즈에 대한 보정이 필요하다.

$$\hat{s}_t = \sum_{i=-1}^1 g_i \cdot s_{t+i} \quad (\sigma = 1, \text{kernel size} = 3) \quad (2)$$

이를 해결하기 위해 가우시안 스무딩을 활용한다. 다만 국소적 특징을 보존하면서 효과적으로 노이즈를 제거하기 위해서 σ 와 커널을 다음과 같이 설정하였다.

나) First-order & Morphological Gradient

유사도의 변화율은 경계 추론에서 핵심적인 단서로 작용하므로, 이를 민감하게 포착하기 위한 기울기 계산은 매우 중요하다.

$$g^{(1)}_t = |\hat{s}_t - \hat{s}_{t-1}| \quad (3)$$

$$m_t = \max_{j \in [-1, 1]} \hat{s}_{t+j} - \min_{j \in [-1, 1]} \hat{s}_{t+j} \quad (4)$$

$$g_t = \alpha \cdot g^{(1)}_t + (1 - \alpha) \cdot m_t \quad (5)$$

1차 기울기 $g^{(1)}_t$ 는 인접한 프레임 간 유사도 차이를 계산 함으로써 급격한 변화를 민감하게 포착한다. 형태학적 기울기 m_t (Morphological gradient)는 국소적인 최댓값과 최솟값의 차이를 구함으로써 완만한 변화의 흐름을 반영한다. 이 두 기울기를 가중치 α 을 통해 적절히 조합하여, 다양한 형태의 이벤트 전환을 포괄하는 유연한 경계 감지가 가능하게 하였다.

다) Dual-threshold + hysteresis

경계를 검출하기 위해서 유사도 변화량이 일정 수준 이상일 때를 의미 있는 변화로 간주한다.

$$S = \{t | g^{(1)}_t > \theta_H\}, \quad W = \left\{t \left| \frac{\theta_H}{2} < g^{(1)}_t < \theta_H \right.\right\} \quad (6)$$

$$\text{Edge} = S \cup \{t \in W | (t-1) \in \text{Edge} \text{ or } (t+1) \in \text{Edge}\} \quad (7)$$

확실한 변화 기준인 θ_H 을 넘은 Strong set과 그에는 미치지 못하는 중간 수준의 변화는 Weak set로 구분하여, 이들의 연속성을 고려한 경계를 설정하였다. 이 과정은 단일 임계값 대비, 노이즈를 억제하면서도 실제 의미 변화를 놓치지 않는 유연한 경계 검출을 가능하게 한다.

2.3 Segment Candidate & Scoring

상승 경계와 하강 경계를 하나의 구간 단위로 구성하고, 이를 조합하여 여러 후보 구간을 생성한다. 이후에 후보 구간에 대한 점수를 계산하여 최종 구간을 선택한다. 점수는 후보 구간 내 유사도인 S_{in} 과 구간 외인 S_{out} 을 활용하여 다음과 같이 정의한다.

$$score_1 = \left(\frac{\text{mean}(S_{in})}{\text{mean}(S_{out})} \right) \quad (8)$$

$$score_2 = \left(\frac{\#\{s \in S_{in} \mid s \geq \text{mean}(S)\}}{\#\{s \in S_{out} \mid s \geq \text{mean}(S)\}} \right) \quad (9)$$

$$score = score_1 + score_2 \quad (10)$$

$score_1$ 은 후보 구간이 전반적으로 쿼리와 얼마나 잘 반영하고 있는지 평가하며, $score_2$ 는 얼마나 고르게 분포하고 있는지 측정한다. 단일 스파이크나 일시적 저하에 의한 오검출을 방지하기 위해 함께 고려한다.

이로써 본 연구의 전체 구조는 프레임과 쿼리 간의 유사도를 계산한 뒤 이를 후처리하여 비디오를 이해하고 최종 구간을 추출하는 방식으로 단순한 구조이지만 효과적으로 구간 추출이 가능하다. 이 과정에서 사용되는 하이퍼파라미터는 두 가지이다. 두 기율기의 결합 비율인 α 와 경계 후보를 판별하는 변화량 임계값인 θ_H 뿐이다.

III. 실험

본 연구는 제안한 방법의 효과를 다각적으로 검증하기 위해 다양한 실험을 설계하고 진행하였다. 먼저, 유사한 구조를 가진 기존 모델들과 비교하여 제안 모델의 위치를 객관적으로 평가하였다. 이어서, 복수의 주석자가 5초 단위 구간 라벨을 제공하는 DiDeMo와 프레임 수준의 정밀한 주석 정보를 포함한 VidSTG를 활용하여 VTG뿐만 아니라 VMR 작업까지 확장하여 정량적인 성능을 검증하였다. 아울러 수치적인 성과만으로는 드러나지 않는 장점을 파악하고자 정성적 분석을 수행하였으며, 임계값 설정이 성능에 미치는 영향을 확인하기 위해 ablation 실험도 함께 진행하였다. 이를 통해, 본 연구가 제안하는 가벼운 접근 방식이 기존 방법들과 비교하여 실질적인 경쟁력과 높은 설명 가능성을 갖추고 있음을 체계적으로 입증하고자 하였다.

3.1 Comparing Models

동영상을 이미지 차원에서 얼마나 효과적으로 이해하고 VTG에 적용했는지 확인하기 위해서 제안 방법과 동일하게 사전학습된 VLM 하나만을 사용하는

모델과 비교했다. Off-the-shelf^[7]는 프레임의 색 변화량을 이용하는 PySceneDetect^[8]를 통해 구간을 생성하고, 대표 프레임을 쿼리와 함께 VLM (CLIP-vit B/16^[6])을 활용한다. 구간-쿼리 유사도를 통해 Watershed를 활용해 구간을 점수화한다.

TFVTG^[5]는 제안 방법과 마찬가지로 프레임과 쿼리 간 유사도를 VLM (BLIP-2 Q-former^[9])으로 계산하는 과정을 거치고, 구간 생성을 위해 Sliding Window를 적용하고 겹치는 후보 제거를 위해 Non-Maximum Suppression (NMS)을 사용한다. 본래 LLM과 방대한 프롬프트를 이용해 더욱 성능을 올리는 구조도 있으나, 목적성에 맞게 LLM을 활용하지 않는 모델을 사용하였다.

* 프레임추출(1), VLM사용(2), 구간생성(3), 점수화(4)

Model	Pipeline	Segment Proposal Methods
Ours	(1)→(2)→(3)→(4)	Similarity Post-processing
Off-the-Shelf ^[7]	(1)→(3)→(2)→(4)	PySceneDetect
TFVTG ^[5] (no LLM)	(1)→(2)→(3)→(4)	Sliding Window + NMS

표 1. 비교 모델들의 파이프라인 구조 및 구간 생성 방식

기존 VTG의 구간생성 방식은 대개 Fine-tuning된 대규모 모델이나, 고정 길이 기반 Sliding Window 방식을 사용해 수많은 후보 구간을 생성하고, NMS 과정을 통해 최종 구간을 선택한다. 대표적으로 TFVTG^[5]가 이에 해당하며, 이러한 접근법은 후보 생성 및 과정의 해석이 어렵다는 한계가 있다. Off-the-Shelf 모델은 PySceneDetect^[8]를 이용해 색 변화 기반으로 구간을 나누고, 쿼리와 일치도를 평가한다. 그러나 이 역시 구간 생성의 이유나 쿼리와 의미적 연관성을 명확히 설명하기 어렵다.

반면 본 연구는 프레임-쿼리 유사도 변화율을 기반으로 경계를 추출하여, 단일 유사도 곡선상에서 구간 선택의 논리를 투명하게 재현할 수 있도록 하였다. 이는 생성 구간의 판단 근거를 질의 수준에서 직관적으로 해석할 수 있다.

3.2 Video Temporal Grounding task Result

제안한 모델과 유사한 사전학습된 단일 VLM만을 사용하는 간결한 Training-free 계열 모델들인 Off-the-Shelf^[7] 및 TFVTG^[5] (no LLM)와 비교했을 때, 성능과 메모리 모두에서 우수한 결과를 보였다. 제안 모델은 훨씬 낮은 GPU 메모리(1GB 미만)로 더 높은

VTG 성능을 달성하였다.

반면, VidSTG 기준으로 SOTA를 기록한 TA-STVG^[1]과 성능 격차가 존재하였다. 이는 TA-STVG가 강력한 비디오 및 이미지 백본을 기반으로 데이터셋에 맞춰 정밀하게 Fine-tuning한 결과로, 단편적 프레임 수준 해석만으로는 특정 데이터에 최적화된 복합 구조를 완전히 능가하기에는 구조적 한계가 있음을 보여준다.

그럼에도 불구하고, 제안한 모델은 학습 없이도 간결한 구조와 최소한의 연산 자원만으로 충분히 경쟁력 있는 성능을 달성하였다. 특히, 실용성과 경량성이라는 측면에서는 상대적으로 복잡한 다른 모델들보다 우수한 효율성을 입증하며, 제한된 환경에서도 효과적으로 활용될 수 있는 대안으로서의 가능성을 제시한다.

DiDeMo에서는 복수의 정답 구간 중 예측 구간과 겹치는 비율인 IoU가 0.5 이상인 경우를 정답으로 간주하여, $R@1(IoU \geq 0.5)$ 기준으로 성능을 평가하였다. VidSTG는 예측 구간과 IoU 평균을 기반으로 하는 m-tIoU를 사용하여 모델의 정밀도를 측정하였다.

Model	DiDeMo (%)	VidSTG (%)	GPU (MiB)
Off-the-Shelf ^[7]	13.31	24.22	1300
TFVTG ^[5]	15.56	24.94	9537
Ours	19.30	39.00	788
TA-STVG ^[1]	-	51.01 (SOTA)	29035

표 2. 모델별 VTG 성능 및 GPU 메모리 사용량 비교

표 2에 따르면 본 모델은 학습 없는 간결한 구조와 최소한의 연산 자원으로도 경쟁력 있는 성능을 달성하였다.

3.3 Video Moment Retrieval task Result

본 모델은 VTG에 맞춰 설계된 경량 구조이지만, 별도의 구조 변경 없이 VMR로 확장하여 유의미한 성능을 달성했다. 나머지 비교 모델이 Fine-tuning이나 VMR에 맞춘 다양한 전략을 사용한 것에 비해 Training-free에서 간단한 구조라는 점에서 대단히 경쟁력 있는 성과라고 볼 수 있다.

가능한 후보 구간 중 모델이 선택한 하나의 예측 구간이, 주어진 복수의 정답 구간 중 하나와 일치할 경우 정답으로 간주하여, $R@1$ 성능을 평가하였다.

Model	DiDeMo (%)	Training (Yes/No)
ClipBert ^[2]	20.4	Fine-tuned (O)
Frozen ^[3]	31.0	Fine-tuned (O)
Ours	36.9	Training-free(X)
CLIP4Clip -seq Transf ^[4]	40.6	Fine-tuned (O)
Human performance	74.75%	

표 3. 모델 별 VMR 성능 비교 및 학습 적용 여부

표 3에 따르면 본 모델은 별도의 구조 변경 없이 VMR로 확장하여 유의미한 성능을 달성하였다.

3.4 Qualitative Analysis

구간 생성 방식에 대한 장점을 검증하기 위해 VidSTG 데이터셋의 한 동영상을 대상으로 정성적 분석을 진행하였다. 대상 영상은 아이가 공을 발로 차고, 굴러 나온 공을 어른이 차는 장면을 포함한다.




그림 2. 데이터(쿼리 + 동영상 + 정답구간)와 모델의 생성 구간 비교

비교 결과, Off-the-Shelf^[7]은 일률적으로 구간을 생성했지만, 제안한 방법은 두 개의 후보 구간을 생성했다. 첫 번째 구간은 실제 Ground Truth에 근접했고, 두 번째 구간은 어른이 공을 차는 장면을 포함했다. 이는 VLM이 "kick"과 "child"라는 쿼리의 핵심 개념은 인식했으나, 동작의 주체에 대한 세부 해석은 부족했음을 시사한다. 이처럼 제안한 방법은 생성 과정과 결과를 모두 직관적으로 해석할 수 있다는 강점을 가지며, 설명 가능성 측면에서 기존 방법들에 비해 강점을 지님을 확인했다.

3.5 Ablation

제안한 이중 임계값 기반 경계 탐지에서 사용한 하이퍼파라미터 θ_H 가 결과에 미치는 영향을 분석하는 ablation 실험을 수행하였다.




그림 3. θ_H 값에 따른 성능 변화

그림 3에 따르면 임계값이 너무 작으면, 노이즈까지 경계로 간주하여 성능이 급락하였다. 반대로 임계값이 너무 클 경우, 유효한 이벤트 구간을 놓쳐 성능이 하락하였다. 그 중간 지점에서 적절히 임계값이 설정된 경우, Baseline과 비교해도 상대적으로 강건하다는 것을 확인할 수 있다. 결국 이는 임계값 설정으로 프레임-쿼리 유사도 변화 기반의 경계 탐지 방식이 실질적으로 효과적임을 보여준다.

IV. 결론 및 향후 연구 방향

본 연구는 추가적인 학습 없이, 단일 VLM과 간단한 후처리만으로 VTG 문제를 해결할 수 있는 경량 프레임워크를 제안하였다. 극히 적은 자원만으로도 효과적인 구간 생성을 달성했으며, 유사한 구조의 모델들과 비교해 성능과 효율성 모두에서 우수한 결과를 보였으며, 경쟁력을 입증했다. 특히 프레임-쿼리 유사도의 변화율을 기반으로 구간을 생성함으로써, 사람이 직접 결과를 추적하고 해석할 수 있는 높은 설명 가능성(explainability)도 확보하였다.

비록 Fine-tuning된 강력한 백본 모델이나 복잡한 해석 구조를 사용하는 기존 방법에 비해 절대적인 성능 우위를 달성하진 않았지만, 단순한 구조와 극히 낮은 연산 자원만으로 거둔 성과는 충분히 주목할 만하다. 특히 본 모델은 추가적인 구조 변경 없이도 VMR 과제에 효과적으로 확장 적용 가능성을 보였고, 이는 제안 방식의 실용성과 확장성을 함께 입증하는 결과라 할 수 있다.

향후 연구에서는 이러한 프레임 수준 해석의 장점을 유지하면서도, 보다 강력한 백본이나 프레임 간 관계를 포착할 수 있는 추가적 모델링 기법을 선택적으로 결합하는 방향이 중요할 것이다. 이는 설명 가능성과 효율성을 기반으로 하면서도 더욱 정밀한 성능 향상을 도모할 수 있는 유의미한 연구 방향이 될 수 있다.

참고문헌

[1] X. Gu, et al. "Knowing Your Target: Target-Aware Transformer Makes Better Spatio-

Temporal Video Grounding," *Proceedings of the International Conference on Learning Representations*, Singapore, 2025.

- [2] J. Lei, et al. "Less Is More: ClipBERT for Video-and-Language Learning via Sparse Sampling," *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 7330–7339, Nashville, Tennessee, USA, 2021.
- [3] M. Bain, et al. "Frozen in Time: A Joint Video and Image Encoder for End-to-End Retrieval," *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 1728–1738, Montreal, Canada, 2021.
- [4] H. Luo, et al. "CLIP4Clip: An Empirical Study of CLIP for End-to-End Video Clip Retrieval and Captioning," *Neurocomputing*, vol. 508, pp. 293–304, 2022.
- [5] M. Zheng, et al. "Training-Free Video Temporal Grounding Using Large-Scale Pre-trained Models," *Proceedings of the European Conference on Computer Vision 2024*, Lecture Notes in Computer Science, vol. 15140, pp. 20–37, Milan, Italy, 2024.
- [6] A. Radford, et al. "Learning Transferable Visual Models from Natural Language Supervision," *Proceedings of the 38th International Conference on Machine Learning*, pp. 8748–8763, Virtual Conference, USA, 2021.
- [7] A. Diwan, et al. "Zero-shot video moment retrieval with off-the-shelf models," in *Proc. of the Workshop on Transfer Learning for Natural Language Processing*, New Orleans, USA, 2022.
- [8] B. Castellano, *PySceneDetect: Intelligent Scene Cut Detection and Video Splitting Tool*, 2022.
- [9] J. Li, et al. "BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models," *Proceedings of the 40th International Conference on Machine Learning (ICML)*, pp. 19730–19742, Honolulu, Hawaii, USA, 2023.